

VILNIAUS UNIVERSITETAS
MATEMATIKOS IR INFORMATIKOS FAKULTETAS
PROGRAMŲ SISTEMŲ KATEDRA

Kursinis darbas

**Objektų atpažinimas ir sekimas kompiuterinės tomografijos
vaizduose**

(Object detection and tracking in computed tomography)

Atliko: 3 kurso Programų sistemų studentas

Paulius Milmantas (parašas)

Darbo vadovas:

Linas Petkevičius (parašas)

Vilnius
2020

Įvadas

Pastaraisiais metais į medicinos sritį labai sparčiai skverbiasi informacinės technologijos. Atliekant įvairias diagnostikas ar tiriant ligas, vaistus yra pasitelkiama programinių sistemų pagalba. Tačiau didžiąją radiologo darbo dalį sprendimus turi priimti jis pats be jokios programinės įrangos pagalbos, nors dažniausiai yra apibrėžti tam tikri ligų aptikimų algoritmai, kaip vėžinių lastelių aptikimas, lūžiai ir taip toliau. Mano darbo tikslas yra prisidėti prie programinės įrangos kūrimo radiologams ir sukurti programą, kuri aptinka plaučius, kad vėliau tai galėtų būti panaudota tolimesnei IT plėtrai medicinos srityje.

Šiandien viena iš labiausiai perspektyvių sričių informacinių technologijų srityje yra giliojo mokymosi metodai. Jie padeda duomenyse aptikti sunkiai pastebimus dėsningumus ir nuspėti išeities rezultatus su tam tikra klaidos tikimybe. Šiame darbe kalbėsiu vieną iš šių metodų: dirbtinius neuroninius tinklus. Juos pasirinkau nes kompiuterinės tomografijos vaizdai turi labai daug informacijos ir juos apdoroti naudojant logines taisykles yra per daug sunku. Tačiau net ir jiems ši užduotis yra per sudėtinga, jeigu tiriamos yra įvairios mutacijos arba nedažnos ligos, nes su kiekvienu nauju nematytu ligos atveju, yra reikalinga apmokyti modelį, o tai reikalauja daug duomenų.

Pasirinktam mano dirbtinių neuroninių tinklų metodui viena iš galimų alternatyvų yra "sprendimo medžiai". Tai yra prižiūravimo mokymosi metodas skirtas duomenų klasifikacijai ir duomenų regresijai. Šis metodas naudoja taisyklių rinkinį. Norint gauti mažą šio metodo paklaidą, turime aprašyti vis daugiau šių taisyklių. Taisyklės paprastai būna aprašomos naudojant "if, else" aprašus.[Seh18] Mano nagrinėjamame atvejuje duomenys yra labai dideli ir įvairūs, todėl aprašyti visas šias taisykles užtruktų neproporcingai daug laiko ir tam tikrų radiologijos žinių.

Turinys

Išvadas	1
1. Dirbtinio neuroninio tinklo sudėtis	3
1.1. Bazinė struktūra	3
1.2. GPU naudojimas	4
2. Aktyvacijos funkcijos	5
2.1. Tiesinė aktyvacijos funkcija	5
2.2. ELU	5
2.3. ReLU	6
2.4. Sigmoid	6
2.5. Softmax	6
2.6. Argumentacija už pasirinktą aktyvacijos funkciją	6
3. Problemos su skaičiaja matematika	8
3.0.1. "Underflow" ir "overflow"	8
3.0.2. Gradientų optimizavimas	8
4. Optimizavimo algoritmai	9
4.1. Gradientinis nuolydis	9
4.2. Poaibio gradientinis nuolydis	9
4.3. Mažo poaibio gradientinis nuolydis	9
4.4. Sunkumai taikant gradientinius metodus	10
4.5. Bendros gradientinių metodų problemos	11
5. Nuostolių funkcijos	12
5.1. Vidutinė kvadratinė paklaida (MSE)	12
5.2. Šaknis iš vidutinės kvadratinės paklaidos (RMSE)	12
5.3. Paklaidų pakelti kvadratu suma	12
6. Neuroninių tinklų modeliai	13
6.1. Mask RCNN inception	14
6.2. SSD MobileNet 1	15
6.3. SSD MobileNet 2	15
6.4. Alternatyvūs objekto paieškos algoritmai	15
Išvados	16
Literatūra	17

1. Dirbtinio neuroninio tinklo sudėtis

1.1. Bazinė struktūra

Daugelį dirbtinių neuronų tinklų sudaro panašios struktūrinės dalys:

1. Įvesties sluoksnis: tai dalis kuri priima įvestį ir perduoda kitiems sluoksniams.
2. Išvesties sluoksnis: tai dalis, kuri naudoja aktyvacijos funkciją kuri grąžina galutinį tinklo rezultatą: tikimybių rinkinį, kuris parodo kokia tikimybė, kad objektas atitinka tam tikrą klasę.
3. Paslėptas sluoksnis: perduoda svorius iš praeito sluoksnio į sekantį.
4. Susijungimai ir svoriai: tarp kiekvieno neurono, kuris yra susijungęs, turi savo svorį, pagal kurį yra pakeičiama perduodama reikšmė.
5. Aktyvacijos funkcija: tai funkcija, kokia turi būti neurono išvestis.
6. Mokymosi taisyklė: apibrėžia, kaip tinkle keičiasi svoriai, kad tinklas išvestų norimus rezultatus.

Dirbtinį neuroninį tinklą taip pat sudaro svoriai ir tendenciškumas. Šie du parametrai yra tinklo automatiškai sugeneruojami ir apmokant tinklą pagal duomenis, svoriai ir tendenciškumas yra automatiškai tinklo keičiami. Tendenciškumas apibrėžia kaip tinklo išvestis yra nutolusi nuo tikrosios reikšmės. Tendenciškumas priartina tinklo išvestį prie tikrųjų reikšmių. Svoriai nurodo koks stiprus yra ryšys tarp neuronų, taip nurodant, kaip tinklo reikšmės kinta pačiame tinkle. Jeigu tinklui yra paduodama reikšmė, o pirmasis tinklo neuronas, kuris priima reikšmę turi mažą svorį, tai reiškia, jog galutiniams rezultatui ši reikšmė neturi daug įtakos. Jeigu svoris yra didelis, tai duota reikšmė turi daug įtakos rezultatui. [Ala16]

Svoriai ir tendenciškumas yra tinklo tvarkomi treniravimo proceso metu. prižiūrimasis tinklo treniravimas vyksta dviem žingsniai: priekine ir atgaline sklaida.

TODO

Atgalinė sklaida vyksta, kai tinklas išveda rezultatą, patikrinama ar rezultatas yra teisingas ir atitinkamai tinklas reaguoja į tai. Inicijuojant tinklą svoriai yra nustatomi atsitiktinai. Kiekvienam duomenų rinkiniui yra stebima tinklo išvestis ir tikrinama kokia ji turėtų būti. Padaryta klaida yra perduodama tinklui atgal, per praeitus sluoksnius, einant nuo išvesties sluoksnio. Šiame žingsnyje yra naudojama optimizavimo funkcija. Ji parodo kokie turėtų būti svorių ir tendenciškumo pokyčiai tinklai ir taip yra keičiami tinklo svoriai ir tendenciškumas atsižvelgiant į padarytą klaidą. Kai klaidos yra padaromos pakankamai mažos ir jos yra mažesnės už duotą ribinę reikšmę, yra laikoma, kad tinklas baigė mokymosi procesą. [Hin18]

1.2. GPU naudojimas

Šiame darbe bus naudojamas GPU, atliekant tinklo treniravimą. Tai yra spartesnis būdas už CPU naudojimą, nes CPU turi kelis galingus branduolius, o GPU žymiai daugiau. Giliajame mokyme, naudojami aritmetiniai veiksmai yra ganėtinai paprasti, todėl juos apdoroti gali ir CPU ir GPU. Tačiau GPU turi daugiau branduolių, kas leidžia atlikti daugiau matematinių veiksmų paralyzuotai, negu CPU. Taip yra pasiekiamas didesnis treniravimo našumas.

Didesniam treniravimo našumui pastebėti naudojant GPU, negu CPU, buvo atliktas paprastas bandymas: naudojant Google tensorflow struktūrą, apmokame sistemą atpažinti kur yra žmogaus plaučiai kompiuterinės tomografijos vaizduose su CPU ir GPU. Vidutiniškai apdorojant 60 megabaitų duomenų, vienam ciklui tinklas su CPU resursais užtrunka 6 sekundes, o naudojant GPU vidutiniškai vienas žingsnis užtrunka 0.3 sekundės.

Šiame darbe naudojamas Tensorflow karkasas naudoja NVIDIA CUDA sistemą. [NVI20b] CUDA yra paralelinio skaičiavimo platforma, naudojama su grafikos plokštėmis. [NVI20a] Ji kiekvieną skaičiavimą paleidžia ant atskiros gijos. Visi duomenys yra suskirstyti į vienos, dviejų ar trijų dimensijų blokus. Kiekvienams blokas gali turėti virš 512 gijų. Visos gijos kurios operuoja viename bloke dalinasi bendra GPU atmintimi. Jeigu norima optimizuoti programą ir paleisti jos skaičiavimus ant GPU, tada reikia suskaičiuoti kiek vyks paralelinių operacijų ir kiek iš jų dalinsis bendra atmintimi. Pagal apskaičiuotą kiekį nurodome kiek mes norime turėti blokų ir kiek kiekvienas blokas turės atskirų gijų. Prieš kiekvieną operaciją, siekiant pasiekti optimalų našumą, jeigu reikia įkeliamė kintamuosiu į bendrą bloko atmintį. Po atliktų skaičiavimų išvestus rezultatus turime iškelti iš bendros atminties.


Tačiau GPU naudojimas nėra visur panaudojamas. GPU gerai atlieka slankaus kabelio operacijas (FLOPs) ir atminties pralaidumų. Jeigu problema reikalauja nepastovios atminties, jos sprendimo paleidimas ant GPU nebus efektyvus, nes nebus galima išnaudoti branduolių, dėl kintančios atminties. Taip pat problemos sprendimas nebus efektyvus, jeigu reikalaus nedaug aritmetiškai intensyvių operacijų.

2. Aktyvacijos funkcijos

2.1. Tiesinė aktyvacijos funkcija

$$R(x, a) = x * a$$

Tiesinės aktyvacijos funkcijos mių diapazonas yra labai didelis ir nėra dvejetainis, kaip dalis kitų funkcijų. Tačiau ši funkcija nėra plačiai naudojama, nes jos išvestinė yra konstanta, kas reiškia jog gautas gradientas nepriklauso nuo 'x'. Taigi, jeigu spėjime yra klaida, vykdant atgalinę sklaidą mes reikšmę taisysime konstanta, neatsižvelgiant į pačią klaidą. [Glo20]




1 pav. Tiesinė lygtis

2.2. ELU

$$R(z) = \begin{cases} z; & z > 0 \\ \alpha * (e^z - 1); & z \leq 0 \end{cases}$$

ELU funkcija vadinasi: 'Exponential Linear Unit'. Ši funkcija paprastai konverguoja į nulį greičiau nei kitos ir taip duoda tikslesnius rezultatus. Skirtingai nuo kitų funkcijų, ši priima papildomai konstantą, kuri turi būti teigiamas skaičius. Ši funkcija yra labai panaši į RELU funkciją, tačiau ELU tampa tolygi lėtai, kol išvestis pasiekia, o RELU staigiai sutolygėja. [Glo20]




2 pav. ELU

2.3. ReLU

$$R(z) = \max(0, z)$$

ReLU funkcija vadinasi: ‘Rectified Linear Unit’. Ši funkcija pasiekia panašų efektyvumą kaip ir Sigmoid funkcija, tačiau ji reikalauja mažiau skaičiavimo resursų nei sigmoid ir tanh, nes minėta formulė yra paprastesnė, nei kitos. [Glo20]



3 pav. ReLU

2.4. Sigmoid

$$R(x) = \frac{1}{1 + e^{-x}}$$

Sigmoid funkcijos parametrai priima realiuosius skaičius ir gražina reikšmę $[0; 1]$. Šios funkcijos geros savybės yra: tolydus gradientas, prognozuojamas išvesties diapazonas, netiesiškumas, visur diferencijuojama ir monotoniška. [Glo20]

2.5. Softmax

$$\text{softmax}(x)_i = \frac{\exp(x_i)}{\sum_{j=1}^n \exp(x_j)}$$

Softmax funkcija priima parametrų skirstinį ir gražina tikimybių skirstinį, kurio bendra suma yra lygi vienam. [Glo20]

2.6. Argumentacija už pasirinktą aktyvacijos funkciją

Šiame darbe bus naudojama Softmax aktyvacijos funkcija. Ši funkcija buvo pasirinkta dėl dviejų priežasčių.

Pirma, galima teigti, kad Softmax funkcija bando optimizuoti entropijos skirtumą tarp tikros reikšmės ir gautos. Entropija tarp tikros reikšmės ‘p’ ir spėjamos ‘q’ yra apskaičiuojama pagal:

$$H(p, q) = - \sum_x p(x) \log q(x)$$

Taip pat entropiją galima aprašyti ir pagal Kullback-Leibler divergenciją:

$$H(p, q) = H(p) + D_{KL}(p||q)$$

Delta p entropijos reikšmė yra lygi nuliui, taip optimizuojama divergencija tarp Kullback-Leibler abiejų distribucijų. Taigi, galime teigti, jog Softmax funkcija bando optimizuoti entropiją tarp tikros reikšmės ir spėjamos. /citesalt6

Antra priežastis yra dėl tikimybinės interpretacijos... TODO

3. Problemos su skaičiaja matematika

3.0.1. "Underflow" ir "overflow"

Ian Goodfellow Yoshua Bengio ir Aaron Courville apibrėžė 'overflow' ir 'underflow' problemas giliojo mokymosi algoritmuose. Minėta 'underflow' problema pasireiškia, kai funkcijos reikšmė yra labai arti nulio ir ji yra apvalinama į nulį. Kadangi kai kurie algoritmai gali 'sulūžti' dėl nulinio parametro (pvz. dalybos iš nulio). Kita problema yra 'overflow'. Ji pasireiškia kai gauta reikšmė yra labai didelė ir ji yra apvalinama į begalybę. [GBC16]

3.0.2. Gradientų optimizavimas

TODO

4. Optimizavimo algoritmai

Tinklo siekiamas tikslas yra atliekant kuo mažiau mokymosi iteracijų, pasiekti norimą išvesties tikslumą. Šiam mokymosi greičiui ir tikslumui pasiekti ir naudojami optimizavimo algoritmai.

4.1. Gradientinis nuolydis

Gradientinio nuolydžio algoritmas Tai yra pati paprasčiausia optimizavimo funkcija.

$$\theta = \theta - \eta * \nabla_{\theta} J(\theta)$$

Pagal algoritmą yra atliekama daug iteracijų. Kiekvienos iteracijos metu yra apskaičiuojama delta. Ji yra gaunama iš esamos deltas atėmus mokymosi žingsnio konstantos ir nuostolių funkcijos gradientą parametro delta atžvilgiu. Kadangi žingsnis kurį atliekame kiekvienos iteracijos metu yra konstanta, jeigu pradinis parinktas taškas yra toli nuo lokalaus minimumo, tai prireiks daug iteracijų, kol jis bus pasiektas. Šiuo metodu taip pat kiekviena iteracija yra peržiūrimi visi duomenys, kad nėra gerai jeigu duomenų yra itin daug. [Dos19] Tokiu atveju reikėtų daug atminties. Šis algoritmas nebus naudojamas, nes nėra atsižvelgta į praeitas iteracijas ir minimumas yra per lėtai pasiekiamas, algoritmas.

4.2. Poaibio gradientinis nuolydis

Šis algoritmas yra panašus į paprastą gradientinį metodą, tačiau yra kelis pakeitimai. Kai yra pereinama per visus duomenis, po kiekvieno duomenų elemento peržiūrėjimo, yra atnaujinami parametrai. Todėl po kiekvienos iteracijos, turime visų duomenų elementų pakeitimų sudėtį. Todėl minimumas yra pasiekiamas statesne trajektorija ir nereikalinga turėti daug atminties. Pagrindinis šio metodo trūkumas yra galimas jo lėtumas. Pereiti per visus duomenis užtrunka daug laiko ir nevisos duomenų elementų iteracijos prie parametrų pakeitimo daug neprisideda. [Dab17]

4.3. Mažo poaibio gradientinis nuolydis

$$\theta = \theta - \eta * \nabla_{\theta} J(\theta; x^{(i:i+n)}; y^{(i:i+n)})$$

Abiejų minėtų algoritmų idėjų kombinacija išvedė mažo poaibio gradientinį metodą. Šis algoritmas suskirsto duomenis į poaibius, kurių elementų skaičius yra daugiau nei 1. Dažniausiai poaibių dydis yra pasirenkamas dvejetas pakeltas koku nors laipsniu, nes vaizdo plokštėms tokius poaibius apdoroja geriau. Šis algoritmas yra greitesnis nei poaibio gradientinis metodas, nes yra išvengiama mažų iteracijų, kurių duomenų elementas mažai prisideda prie parametrų pakeitimo. Taip pat šio metodo pasiekiamas tikslumas yra didesnis nei kitų minėtų algoritmų, nes atsitiktinai parenkami poaibiai skiriasi kiekvieno poaibių paskirstymo metu, taip sudarant daugiau variacijų ir

daugiau triukšmo. Kadangi bendrai yra apdorojama daugiau duomenų variacijų, šis metodas gali pasiekti didesnę tikslumą. Nors šis metodas gali pasiekti didesnę tikslumą ir yra greitesnis. [Dab17]

4.4. Sunkumai taikant gradientinius metodus

1. Mokymosi žingsnio nurodymas. Tikslaus sprendimo nurodančio koki žingsnį parinkti nėra, jis paprastai yra parenkamas empiriškai stebint konvergavimo greitį ir duomenų kiekį. Jeigu žingsnis yra parenkamas per didelis, tai optimizavimo funkcija gali diverguoti arba peršokti lokalų minimumą ir nutolti nuo jo, taip prailginant procesą. Jeigu žingsnis yra parenkamas per mažas, tada konvergavimo greitis į lokalų minimumą yra labai mažas ir procesas trunka ilgai. [Rud16]
2. Mokymosi žingsnio keitimo trigeris. Kuriant "trigerį" reikia nurodyti arba epochų skaičių arba ribinę nuostolių funkcijos reikšmę, kada trigeris turi būti aktyvuotas. Po aktyvacijos, trigeris pakeičia mokymosi žingsnio dydį. Trigerio aktyvacijos laiko nurodymui irgi nėra jokios tikslios taisyklės, tai yra nurodoma empiriškai stebint mokymosi procesą. Jeigu aktyvacijos laikas yra nurodomas per anksti, mokymosi žingsnis yra sulėtinamas per greitai ir funkcija pradeda lėčiau diverguoti į minimumą. Jeigu žingsnis yra nurodomas per vėlai, tam tikru momentu žingsnis gali būti per didelis ir funkcija gali pradėti diverguoti arba peršokti lokalų minimumą ir tolti nuo minimumo. [Rud16]
3. Duomenų rinkinio parinkimas. Jeigu daug duomenų turi tuos pačius požymius, pagal kuriuos tinklas klasifikuoja rezultatus, visų šių duomenų iteracija nėra būtina, nes jie tinklo svorių pokyčius įtakos labai nežymiai. Jeigu duomenų, su panašiais požymiais, yra daug, reikia paimti tik dalį jų ir tik tą dalį iteruoti. Jeigu duomenų, su panašiais požymiais, yra daug, tada tinklo vienos epochos trukmė gali užtrukti ilgiau ir optimizavimo funkcija lėčiau konverguos į lokalų minimumą. [Rud16]
4. Optimizavimo funkcijos "užstrigimas" ties lokaliu minimumu. Optimizavimo funkcijų tinklas yra rasti globalų minimumo tašką. Tačiau gradientų nuolydžiu pagrįstų algoritmų dažna problema: "užstrigimas" ties lokaliu minimumu. Gradientas parodo kuria kryptimi funkcija leidžiasi žemyn. Ta kryptimi optimizavimo algoritmas eina. Pasiekus lokalų minimumą, kai gradientas pradeda didėti, optimizavimo algoritmai baigia darbą. Todėl jeigu yra blogai parenkamas pirmas taškas, optimizavimo algoritmai "užstrigs" ties lokaliu minimumu. [Rud16] Tą išvengti galima prieš algoritmo pradžią įvertinti funkciją ir parinkti artimus pradinius taškus prie tikrųjų reikšmių. Kitas būdas to išvengti yra naudoti optimizavimo algoritmus, kurie nesiremia gradientų nuolydžiu. Vienas iš daugelio algoritmų, kuris nesiremia gradientais, yra banginių judesių pagrįstas optimizavimo algoritmas.

Minėtas banginių optimizavimo algoritmas buvo sukurtas stebint banginių judėjimą, jiems gaudant mažas žuvis. Gaudant žuvis banginiai negali padaryti status posūkio, todėl gaunant žuvis jie

juda aplink žuvis ir po kelių ratų jie pasiekia apskritimo centrą ir pagauna žuvis. Šis algoritmas yra pagrįstas būtent šiuo judėjimu. [Sey16]

```

Randomly initialize the whale population.
Evaluate the fitness values of whales and find out the best search agent  $X^*$ .
while  $t < t_{\max}$ 
    Calculate the value of  $a$  according to Equation (13)
    for each search agent
        if  $h < 0.5$  then
            if  $|A| < 1$  then  $X(t+1) = X^*(t) - A \cdot D$ 
            else if  $|A| \geq 1$  then  $X(t+1) = X_{\text{rand}}(t) - A \cdot D''$ 
            end if
        else if  $h \geq 0.5$  then
             $X(t+1) = D' \cdot e^{bl} \cdot \cos(2\pi l) + X^*(t)$ 
        end if
    end for
    Evaluate the fitness of  $X(t+1)$  and update  $X^*$ 
end while

```

4 pav. Banginių optimizavimo algoritmas [Sey16]

4.5. Bendros gradientinių metodų problemos

Gradientinio nuolydžio metodai yra pirmo laipsnio optimizavimo funkcijos, kas reiškia jog jos naudoja tik pirmo laipsnio išvestines. Kadangi pirma išvestinė rodo tik funkcijos statumą, bet ne išlenktumą, tai:

1. Jeigu antra išvestinė yra lygi nuliui, tai funkcija yra tiesinė. Todėl, mokymosi žingsnis yra lygus alpha. [Dab17]
2. Jeigu antra išvestinė yra didesnė už nulį tai funkcijos išlenktumas eina į viršų. Todėl funkcijos žingsnis yra mažesnis už mokymosi žingsnį ir optimizavimo funkcija gali diverguoti. [Dab17]
3. Jeigu antra išvestinė yra mažesnė už nulį, tai funkcija yra išlenkta į apačią. Todėl funkcijos žingsnis yra didesnis už mokymosi žingsnį. [Dab17]

To pasekoje, optimizavimo funkcijos greitis gali būti lėtas arba ji gali diverguoti.

5. Nuostolių funkcijos

Nuostolių funkcijos grąžina skirtumą tarp tinklo išvesties ir tikrų reikšmių. Pagal nuostolių reikšmes yra atitinkamai apskaičiuojami gradientai ir atitinkamai keičiami tinklo svoriai ir tendenciskumas.

5.1. Vidutinė kvadratinė paklaida (MSE)

$$Nuostolis = \frac{1}{N} * [\sum (Y_{Gautas} - Y_{Tikras})^2]$$

MSE funkcija sumuoja skirtumų kvadratus ir randa bendrą nuostolių vidurkį. Ši funkcija yra dažnai numatyta įvairiuose MATLAB ir Python algoritmuose. Vienintelė neigiama šios funkcijos pusė yra tai, kad jeigu duoti duomenys yra pirmojo laipsnio, tada negalima teigti, kad rezultatai tiesiogiai koreliuoja tarpusavyje, nes MSE yra antrojo laipsnio funkcija. [Kat19]

5.2. Šaknis iš vidutinės kvadratinės paklaidos (RMSE)

$$Nuostolis = \sqrt{\frac{1}{N} * [\sum (Y_{Gautas} - Y_{Tikras})^2]}$$

RMSE funkcija yra panaši į MSE, tik pridėta šaknies traukimo operacija. Šaknies traukimas paverčia RMSE pirmojo laipsnio funkcija, todėl ją galima naudoti su pirmojo laipsnio duomenimis. [Kat19]

5.3. Paklaidų pakelti kvadratu suma

$$Nuostolis = [\sum (Y_{Gautas} - Y_{Tikras})]^2$$

]subsectionArgumentacija už pasirinktą aktyvacijos funkciją TODO

6. Neuroninių tinklų modeliai

Objektų aptikimas nuotraukose, taikant dirbtinius neuroninius tinklus, gali būti kelių tipų: objektų klasifikacija, objektų lokalizacija, semantinė segmentacija, objektų segmentacija (instance segmentation).

Objektų klasifikacijos tinklas gražiną reikšmę nusakančią ar vaizde yra objektas ar jo nėra. Klasifikacijos uždavinį sprendžiant yra pradedama nuo duomenų normalizacijos. Visi vaizdai yra padidinami ar sumažinami iki tam tikro dydžio. Galima taip pat pašalinti vaizdų RGB kanalą ir padaryti juos bespalviais. Norint padidinti esamą duomenų rinkinį šiame darbe buvo naudotas Gauso filtras kiekvienai nuotraukai. Su kiekviena nuotrauka buvo sugeneruotas dar 5 papildomos su skirtingai Gauso filtro parametrais. Šis metodas taip pat padeda neuroniniam tinklui neprisirišti prie tam riktų pikselių reikšmių. Taip pat vaizdus galima pakreipti ir kitaip modifikuoti, tačiau plaučių aptikimo tomografiniuose vaizduose uždavinyje, tas nebuvo atliktas, nes organai dažniausiai išlaiko savo proporcijas. Po duomenų normalizacijos reikia žiūrėti duomenų parametrus ir pagal tai sukonstruoti pirmąjį tinklo sluoksnį. Paprastai pirmą sluoksnį nusako:

$$N_{Pirmas_{sluoksnis}} = X_{VaizdoPlotis} * Y_{VaizdoAukis} * N_{SpalvKanalSkaiius}$$

Sprendžiant plaučių aptikimo kompiuterinės tomografijos nuotraukose uždavinį, buvo naudojamas RGB kanalų pašalinimas. Taip buvo sumažintas pirmasis tinklo sluoksnis tris kartus ir paleidžiant sprendimą prireikė mažiau atminties. Paskutinis tinklo sluoksnis priklauso nuo to, kokius mes rezultatus norime gauti. Jeigu norime pasakyti koks objektas yra nuotraukoje, galima naudoti tokią išvesties sluoksnio dydį, kiek yra klasių modelyje. Norint taip pat aptikti ir kur vaizde yra atpažintas objektas tinklo išvesties sluoksnio dydis turi būti:


$$N_{Ivesties_{sluoksnio_{dydis}}} = C_{KlasiSkaiius} * 5$$

Klasių skaičius yra dauginamas iš 5, nes norime gauti pačios klasės tikimybę ir tikėtinas viršutines ir apatines objekto x ir y reikšmes. Jeigu norime gauti ne tik x ir y reikšmes, bet tiksliai objekto kiekvieno taško koordinates, kad tiksliai žinotume objekto ribas, reikia sudėtingesnio modelio, kuris vertintų kiekvieno vaizdo pikselio tikimybę, kad jis priklauso tam tikrai klasei. Šio modelio įvesties sluoksnis lieka toks pat kaip ir kitų, tačiau keičiasi išvesties sluoksnis. Jis tampa lygus:

$$N_{IvestiesSluoksnis} = C_{KlasiSkaiius} * X_{VaizdoPlotis} * Y_{VaizdoAukis}$$

Taip galima nusakyti kuriai klasei priklauso kiekvienas pikselis ir nusakyti, kokios yra kiekvienos klasės ribos vaizde.

Šiame darbe yra naudojamas Tensorflow karkaso Mask RCNN inception modelis, kuris naudoja objektų segmentavimą. Tinklo modelį ištreniruoti ir nusakyti kur yra tiksliai plaučių ribos nuotraukose, buvo naudojami dvejetainių reikšmių "png" failai. Vienas iš tokių failų pavyzdžių:



5 pav. Vaizdo kaukė.

Šiam uždaviniui tokio tipo failai buvo pasirinkti tam, nes reikia aptikti dvi klases: plaučiai ir ne plaučiai. Taip su skirtingomis pikselių reikšmėmis yra paduodamos kiekvieno pikselio klasės. Šie dvejetainiai vaizdų failai buvo gauti apibrėžiant plaučius kiekvienoje nuotraukoje ir eksportuojant pažymėtus ribinius taškus į "XML" failus. Pagal duotas ribinių taškų X ir Y koordinates, buvo parašyta programa, kuri automatiškai pagal turimus duomenis sugeneruoja dvejetainius vaizdų failus.

6.1. Mask RCNN inception

Mask RCNN modelį sudaro dvi dalys: vaizdo regiono pasiūlymo tinklas (Regional proposed network) ir klasifikavimo modelis. [Kha19] Bendras algoritmas:

1. Nuotrauka yra praleidžiama per konvoliucinį neuroninį tinklą (R-CNN), kuris sugeneruoja požymių aibę, pagal kurią galima nuspėti, kad tai yra ieškomas objektas ir kur būtent jis yra vaizde.
2. Vaizdo regiono pasiūlos algoritmas naudoja CNN, kad sugeneruotų regionus vaizde pagal gautą požymių aibę.
3. Sulyginus gautis regionus gaunamos koordinatės, kurios apibrėžia objektą.
4. Naudojant regresijos modelius objekto apibrėžimas yra tikslinimas, kol gaunami optimalūs rezultatai.
5. Rezultatai yra persiunčiami į kitą CNN tinklą, kuris sugeneruoja vaizdų kaukes, atitinkančias klases.

Tinklas gauna vaizdo regionus, kurie turi didesnę tikimybę turėti objektą, naudodamas 9 inkarinių apibrėžimų koordinates. 3 inkariniai apibrėžimai yra skirtingų formų. Kiekvienam šiam apibrėžimui yra sukuriama dar 2 apibrėžimai, kurių formos yra vienodos, tačiau jų dydžiai skiriasi. Šiais 9 inkarais yra pereinama per vaizdą su kiekvienu inkaru ir kiekvienas inkaro apibrėžtas vaizdas yra analizuojamas: siunčiamas per CNN ir gaunama tikimybė, kad tai yra tam tikra klasė. Su kiekvienu uždaviniu yra patartina patiems apibrėžti kokios formos turi būti inkarai. [Gao17] Pavyzdžiui jeigu uždavinys yra aptikti plaučius kompiuterinės tomografijos nuotraukose, inkarai

turėtų būti didesni į aukštį ir mažesni į plotį ir 3 inkarai iš 9 turi būti kvadrato formos, nes jeigu analizuojamas plaučių viršus nuotraukose, tai jis yra apvalus, o ne pailgas.

Turint daug inkarų sudarytų vaizdų, reikia atskirti kurie vaizdai yra fonas, o kurie yra objektas. Foninių vaizdų negalima traukti į regresijos modelį, o objekto vaizdus reikia. Šis regresijos modelis yra naudojamas pataisyti inkaro sukurtą vaizdą, kad jis apibrėžtų tik objektą. [Gao17]

Po šių veiksmų vaizdai yra sugeneruojama daug objektų apibrėžimų. Dalis šių apibrėžimų kerta tarpusavyje. Apibrėžimai kurie kerta tarpusavyje yra išsaugomi ir vėliau toliau analizuojami. [Gao17] Kiekvienam kirtimui yra apskaičiuojamas kirtimosi koeficientas:

$$K = \frac{N_{PirmasObjektas} \cap N_{AntrasObjektas}}{N_{PirmasObjektas} \cup N_{AntrasObjektas}}$$

Jeigu koeficientas yra lygus 1, tai reiškia jog inkarų apibrėžimai sutampa idealiai. Jeigu koeficientas yra mažesnis už arba lygus 0.5, tada apibrėžimai nėra naudojami. Jeigu koeficientas yra didesnis už 0.5, sankirta yra išsaugoma tolimesnei analizei. Atlikus paiešką, kiekvienam atskiram objektui yra parenkama tik sankirta su aukščiausiu sutapimo koeficientu ir kiti apibrėžimai apie einamąjį objektą yra pašalinami. Po šių žingsnių yra gaunami apibrėžimai aplink kiekvieną objektą, ir jų yra tik po vieną. Kiekvienas šis apibrėžimas yra siunčiamas per kitą CNN tinklą, kuris analizuoja kiekvieno pikselio reikšmę ir nustato tiksliai objektų ribas. [Gao17]

6.2. SSD MobileNet 1

6.3. SSD MobileNet 2

6.4. Alternatyvūs objekto paieškos algoritmai

Išvados

Išvadose ir pasiūlymuose, nekartojant atskirų dalių apibendrinimų, suformuluojamos svarbiausios darbo išvados, rekomendacijos bei pasiūlymai.

Literatūra

- [Ala16] Jay Alammar. A visual and interactive guide to the basics of neural networks, 2016. URL: <http://jalammar.github.io/visual-interactive-guide-basics-neural-networks/> (tikrinta 2020-04-30).
- [Dab17] Imad Dabbura. Gradient descent algorithm and its variants, 2017. URL: <https://towardsdatascience.com/gradient-descent-algorithm-and-its-variants-10f652806a3> (tikrinta 2020-04-30).
- [Dos19] Sanket Doshi. Various optimization algorithms for training neural network, 2019. URL: <https://medium.com/@sdoshi579/optimizers-for-training-neural-network-59450d71caf6> (tikrinta 2020-04-30).
- [Gao17] Hao Gao. Faster r-cnn explained, 2017. URL: <https://medium.com/@smallfishbigsea/faster-r-cnn-explained-864d4fb7e3f8> (tikrinta 2020-04-30).
- [GBC16] Ian Goodfellow, Yoshua Bengio ir Aaron Courville. *Deep Learning*. MIT Press, 2016. <http://www.deeplearningbook.org>.
- [Glo20] ML Glossary. Activation functions, 2020. URL: https://ml-cheatsheet.readthedocs.io/en/latest/activation_functions.html (tikrinta 2020-04-30).
- [Hin18] Knut Hinkelmann. Neural networks, 2018. URL: http://didattica.cs.unicam.it/lib/exe/fetch.php?media=didattica:magistrale:kebi:ay_1718:ke-11_neural_networks.pdf (tikrinta 2020-04-30).
- [Kat19] Chayan Kathuria. Regression — why mean square error?, 2019. URL: <https://towardsdatascience.com/https-medium-com-chayankathuria-regression-why-mean-square-error-a8cad2a1c96f> (tikrinta 2020-04-30).
- [Kha19] Renu Khandelwal. Computer vision: instance segmentation with mask r-cnn, 2019. URL: <https://towardsdatascience.com/computer-vision-instance-segmentation-with-mask-r-cnn-7983502fcad1> (tikrinta 2020-04-30).
- [NVI20a] NVIDIA. Cuda zone, 2020. URL: <https://developer.nvidia.com/cuda-zone> (tikrinta 2020-04-30).
- [NVI20b] NVIDIA. Gpu support, 2020. URL: <https://www.tensorflow.org/install/gpu> (tikrinta 2020-04-30).
- [Rud16] Sebastian Ruder. An overview of gradient descent optimization algorithms, 2016. arXiv: 1609.04747 [cs.LG].
- [Seh18] Shirag Sehra. Decision trees explained easily, 2018. URL: <https://medium.com/@chiragsehra42/decision-trees-explained-easily-28f23241248> (tikrinta 2020-04-30).

[Sey16] Andrew Lewis Seyedali Mirjalili. The whale optimization algorithm, 2016.
URL: https://www.sciencedirect.com/science/article/pii/S0965997816300163?casa_token=yI9V7so44bIAAAAA:y_34ijm8Gc4JBsknYd7cH2hqfk2K4h6dpYxZBTR7RGCEa89wP2b50hl_FqhK8t8gG9r4qdmGCg (tikrinta 2020-04-30).